

# 王帅

## AI Agent 应用工程师 (Java / 全栈)

- ◆ AI 应用 / Agent 工程 ◆ 多模态 LLM ◆ Codex / Cursor / Claude Code
- ◆ Java / Python / TypeScript ◆ 全栈工程 ◆ 系统架构
- ◆ 中间件 / 分布式系统

电话 / 微信: 18210237734

邮箱: mkwork@qq.com

期望城市: 优先北京, 其他城市可沟通

到岗时间: 随时到岗

## 个人概述

拥有 10 年+ 软件研发经验, Java 后端出身, 近两年聚焦 AI 应用与 Agent 工程, 可使用 Java、Python 和 TypeScript/React 完成从后端服务、模型编排到前端交互的端到端交付。长期负责技术架构设计与核心开发, 先后建设统一存储、消息与 MQ 中间件、测试环境、CI/CD 以及 AI 答疑、生图和错因诊断等平台。擅长复杂业务抽象、分布式系统可靠性、多模态 LLM 应用、异步流水线、海量数据治理与线上问题闭环。

## 核心能力

|                                                                                                                                   |                                                                                                                            |
|-----------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------|
| <b>AI 应用与 Agent 工程</b><br>多模态 LLM、Prompt/上下文组装、意图路由、结构化输出、RAG、模型降级与异步工作流; 熟悉 Langfuse 的 Prompt 管理、Trace 和效果评估链路。                  | <b>AI Agent 研发工具</b><br>实际使用 Codex、Cursor、Claude Code 辅助需求分析、代码库理解、技术方案设计、跨仓库开发、代码重构、测试补充、故障排查和文档沉淀, 具备 AI 协同研发与端到端任务交付经验。 |
| <b>Java / Python 后端</b><br>Java、Python、Kotlin, Spring Boot/Spring MVC、FastAPI、Dubbo/Triple、Protobuf; 具备服务拆分、接口契约、任务状态机、并发与幂等设计能力。 | <b>全栈交付</b><br>TypeScript、JavaScript、React、HTML、CSS, 熟悉 SSE、WebSocket、WebView JS Bridge 和对话式 AI 产品交互, 能独立打通前后端链路。          |
| <b>数据与中间件</b><br>MySQL、MongoDB、Elasticsearch、Redis、RocketMQ/ONS、OSS/CDN; 具备索引优化、分表治理、缓存与数据一致性、消息可靠投递实践经验。                         | <b>平台与工程化</b><br>技术架构设计、Kubernetes、Docker、Jenkins、GitLab CI/CD、Apollo、OIDC/SSO, 熟悉灰度发布、失败补偿、链路观测、自动化测试与线上故障排查。             |

## 工作经历

### 高思教育 / 爱学习 | 软件研发工程师

2017.08 – 2026.08

- 长期负责公司级技术平台与教育业务系统的架构设计和核心开发, 覆盖需求分析、技术方案、核心编码、联调上线、监控排障和持续演进。
- 以 Java 后端为核心, 建设统一存储、消息平台和 MQ SDK 等公司级中间件, 并参与测试环境与 CI/CD 平台建设, 支撑多业务线的研发与交付。
- 近两年转向 AI 应用与全栈开发, 主导或深度参与 AI 答疑、AI 学伴、AI 生图、错因诊断与订正分析等项目, 完成从模型接入、工作流编排、数据治理到 React H5 交互的端到端落地。
- 持续处理高并发异步任务、海量数据、多云存储、消息可靠性、服务治理和线上故障等问题, 兼顾快速业务交付与长期可维护性。

# AI 应用项目

## 错因分析与订正诊断系统

2026.01 – 2026.08

面向教育场景构建多模态 AI 分析平台，形成错因诊断（文字诊断与图片批注）、订正诊断、易错点聚类三大业务流水线。

Python / FastAPI / Dubbo Triple / MongoDB / MySQL / Elasticsearch / RocketMQ / Langfuse

- 主导系统架构设计与核心开发，打通 4 类业务来源及 MySQL、MongoDB、Elasticsearch、OSS、RocketMQ，搭建从任务接入、异步处理到结果回传的完整链路。
- 设计基于 MongoDB 原子锁的多阶段任务状态机，实现多节点并发、超时回收、指数退避重试与幂等控制，支撑错因诊断、订正申诉、图片批注和消息通知独立演进。
- 构建多模态 LLM 分析流程，实现可分析性预检、错因分类与解释、订正正确性/有效性判断，并统一管理 4 类业务来源的题目与作答上下文。
- 自研坐标式图片批注能力，实现坐标归一化、空白检测、文字避让及中文/LaTeX 混排，线上累计承载约 28.8 万次；相比原 Gemini 生图方案，单次模型生成成本由约 ¥0.48 降至 ¥0.15（降低约 69%），平均耗时由 19.3 秒降至 12.9 秒（缩短约 33%）。
- 接入 Langfuse Prompt 管理和跨阶段 Trace，结合 Pinpoint、结构化日志与 Mongo 慢请求监控完善链路可观测性；当前 117 项自动化测试全部通过。

## AI 答疑平台

2024.08 – 2025.12

面向学习机与教学产品构建多模态 AI 学习平台，覆盖 AI 答疑、AI 学伴和 AI 生图三大业务模块。

Java / Spring Boot / Dubbo / MongoDB / React / TypeScript / 多模态 LLM / Dify RAG / SSE / WebSocket / OSS

- 设计并实现接口契约、数据服务、Spring Boot AI 接入层和 React H5 客户端四仓架构，通过 Dubbo/Triple 聚合题库、学生、聊天记录、错因及订正等内部服务，打通 App WebView、模型调用与 MongoDB/MySQL/Elasticsearch 数据层。
- 构建题目级 LLM 答疑编排，按题干、解析、知识点、学生信息和作答状态动态组装 Prompt，支持意图路由、多模态手写分析、Dify RAG、流式输出及模型失败切换；线上累计承载约 39.1 万次答疑会话，最近 30 天约 6.72 万次、覆盖 8,534 名学生。
- 基于 JS Bridge 打通学习机题目切换、手写笔、作答状态、键盘和窗口控制，以参数驱动状态机复用文字答疑、语音、学习提醒和学伴等多种交互形态。
- 建设答后学伴闭环，将学生作答、错因文字和批注图注入对话，支持错因反馈、订正任务防重、异步结果轮询及历史恢复；学伴累计承载约 7.3 万次会话，最近 30 天约 1.00 万次、覆盖 2,564 名学生。
- 从零构建对话式 AI 生图系统，支持文本/参考图、多轮调整、Prompt 润色及风格/分辨率控制；设计 OSS 与 MongoDB 会话瘦身方案，累计生成 7,562 张图片，生成耗时中位数约 15.4 秒。

# 研发效能平台

## iFlow 持续交付平台

2023.09 – 2025.01

面向研发与运维建设预发/生产一体化持续交付平台，将应用、迭代、Git 分支、发布审批、CI/CD 流水线、制品、部署状态和回滚纳入统一 workflow，覆盖 Kubernetes 与虚拟机交付场景。

Java / Spring Boot / React / Jenkins / GitLab / Kubernetes / Docker / MySQL / Redis / WebSocket / OIDC

- 负责五仓协同的持续交付平台架构设计与核心开发，打通迭代分支/MR、预发与生产审批、可视化流水线、Jenkins 构建、制品入库、Kubernetes/虚拟机发布、结果通知和历史制品回滚。
- 负责空间与制品中心核心能力，完成空间 CRUD/订阅及制品上传、下载、分页、删除、分支/模块元数据、PVC 持久化、上传限制、权限控制和操作审计，实现 CI 制品统一沉淀并支撑 CD 与回滚复用。
- 建设制品上传/拉取及 Kubernetes/虚拟机部署 Stage，适配前端、Spring Boot、Tomcat 等交付形态，通过错误中止、敏感日志收敛和 kubedog 就绪跟踪增强发布可靠性。
- 打通 React/xterm.js 与 Java WebSocket 实时交互链路，实现 Jenkins/Kubernetes 日志、Pod Exec、Trzsz 文件上传下载和 Terminalizer 操作留痕，提升线上排障效率与可追溯性。
- 建设 OIDC/SSO 登录退出链路，处理服务端拦截、前端 401 重定向、Cookie/Token、单点退出和白名单，并接入统一 SSO SDK，形成从研发流程、持续交付到运行排障的一体化平台能力。

## 蜂巢测试多环境管理平台

2022.05 – 2024.04

面向研发、测试和运维构建一站式测试环境平台，以公共环境作为共享底座、私有环境按迭代部署最小服务集合，通过 HTTP/RPC 双通路由实现未部署服务透明回退，降低完整环境的重复建设与维护成本。

Java / Spring Boot / Kubernetes / Jenkins / Nginx/OpenResty / Java Agent / Javassist / Dubbo / Zookeeper / Shell

- 负责公共/私有测试环境的全生命周期架构与核心开发，打通项目与分支选择、Jenkins 构建、Kubernetes 发布、服务启停、Pod/健康状态、Nginx/Zookeeper 管理及告警通知，支持快速复制和启动隔离联调环境。
- 设计并演进 Dubbo 跨环境 Java Agent，基于 Instrumentation、Javassist 和动态代理扫描 XML/注解服务引用，按自定义、私有、公共注册中心优先级路由，并维护服务发现缓存及 Alibaba/Apache Dubbo 制品适配，实现业务代码无侵入的服务复用。
- 完善 Jenkins/Kubernetes 标准化发布体系，沉淀高复用 Shell 与部署模板，降低 Jenkins 插件依赖，覆盖 Java 8/17/21、Spring Boot、Tomcat、Node.js、Python 及常用中间件，并通过 Volume/NAS 支撑配置与数据持久化。
- 重构 Nginx/OpenResty 跨环境访问链路，以 Lua 探测私有服务并缓存路由结果，未部署服务自动回退公共环境，同时支持免配 Hosts、CORS、WebSocket 和 SSE。
- 实现 OIDC/SSO 权限接入、单点退出及用户缓存，并完成 iTest、iFlow、GitLab 等研发工具集成。

存储服务

2017.10 – 2022.08

面向公司业务系统从零建设统一对象存储平台，以 Web/OpenAPI、Dubbo 服务、异步任务和管理后台四层架构，统一封装多云存储的上传、访问、热备及配置治理能力。

Java / Spring MVC / Dubbo / MySQL / Redis / 阿里云 OSS / 七牛云 / CDN / RocketMQ / Vue.js

- 主导四层系统架构设计与核心开发，统一七牛云和阿里云 OSS 的上传签名、分片上传、回调、公开/私有 URL、批量下载及短链能力，业务方无需感知底层 Bucket、鉴权与云厂商差异。
- 设计 BusinessKey 驱动的多 Bucket、多 CDN 动态路由，通过 MySQL 配置与 Redis 缓存管理存储可用状态、访问域名和私有读策略，支持存储切换、配置热更新及多业务隔离。
- 实现带版本号与摘要校验的可逆短链方案，通过 XOR、位序变换和自定义 Base62 隐藏连续 ID，解码后按 ID 直接路由分表并结合 Redis 热点缓存，实现短码防误改、历史版本兼容及稳定低成本查询。
- 建设 MQ 驱动的跨云热备链路，将上传回调、任务持久化、七牛/阿里云异步复制、失败重试和短信/邮件告警串联为完整闭环，提升资源可用性和故障恢复能力。
- 针对持续增长的文件元数据、短链和热备数据设计分表治理机制，自动巡检最大 ID、预建下一张表并按阈值切换，支撑累计约 28.2 亿条文件元数据记录；截至 2026-08，管理七牛与阿里云两侧合计约 1.01 PB 云端存储容量，覆盖七牛 16.29 亿个对象、阿里云 73 个 Bucket，阿里云 CDN 近 7 天处理 27.97 TB 流量及 1.5 亿次请求。
- 完善 OpenAPI/SDK/管理端分层鉴权、上传类型白名单、回调校验、私有 URL 时效及敏感信息脱敏，并持续推进依赖漏洞治理与 JDK 21、Spring Boot、Dubbo 3 升级。

消息平台（短信邮）

2018.05 – 2023.08

面向公司业务系统建设短信、邮件、语音一体化消息基础设施，通过 API JAR、Dubbo 服务、HTTP 网关和管理后台提供统一接入、异步发送及运营治理，并兼容旧版消息链路。

Java / Spring / Dubbo / RocketMQ / MySQL / Redis / Quartz / Vue.js / 阿里云短信/邮件/语音

- 负责统一消息平台架构设计与核心开发，拆分 API 契约、Dubbo 执行服务、HTTP 接入和 Vue 管理端，以 RocketMQ 解耦业务请求与第三方渠道调用，统一三类消息的 Task ID 和接收人级结果查询。
- 设计 App Token + 模板授权的应用接入模型，并将模板、渠道账号、主备策略、MQ Queue、白名单和发送记录数据化管理，实现多业务隔离、发送权限与环境治理。
- 建设阿里云、漫道、创蓝短信多渠道路由，支持主渠道失败自动切换漫道补发；结合 retryId 源记录关联、第三方回调和定时状态补偿形成最终送达闭环。
- 完善 Redis 短时间消费防重、ONS 自动重试、定时任务多节点互斥、营销退订过滤及线下白名单，提升异步消息链路的可靠性、可追踪性和误发防护能力。
- 新旧短信链路累计沉淀约 6,748 万条接收人级发送记录，最近 30 个完整自然日合计约 30.66 万条、日均约 1.02 万条（包含渠道补发记录）。
- 维护旧版 MQ/Dubbo 链路兼容存量业务，并推进 Java 21、Spring/Dubbo 及 HTTP 服务 Spring Boot 化改造，支撑长期运行系统的平滑演进。

# 中间件

## MQ 中间件 SDK

2019.02 – 2025.05

面向公司业务线建设统一 MQ Java SDK，以 Maven JAR 形式发布至 Nexus，封装阿里云 ONS/RocketMQ 的消息生产、消费及可靠性治理能力，被多个业务系统复用。

Java / 阿里云 ONS/RocketMQ / Spring / Maven / Protobuf / Redis / MySQL

- 负责企业级 MQ Java SDK 架构设计与核心开发，基于 Protobuf 与注解扫描统一 Topic/Tag 路由和监听器注册，支持普通/延时消息、自定义 Key、多 Topic、同步/异步及集群/广播消费。
- 建设正式与灰度集群的消息隔离机制，通过 Consumer Group、Tag 后缀、消息白名单/黑名单及时间窗口，实现同一消息互斥消费，支撑业务灰度切流与安全回滚。
- 完善消息可靠性设计，基于 Redis 业务 Key 实现消费幂等，并以 Lua 原子 SET NX EX 解决 Jedis 版本兼容及中间状态问题；结合 ONS 自动重试、失败消息落库与定时补偿形成异常闭环。
- 推动 NameServer、消费线程、超时、重试次数及 Topic 映射配置化，并将 SDK 通过 Maven/Nexus 统一交付，降低业务线 MQ 接入和多环境迁移成本。

## 教育经历

东北林业大学 · 本科

2021 – 2023

中原工学院 · 大专

2009 – 2011

## 其他亮点

软件著作权 · AI 答疑系统、AI 生图系统。